

ΠΕΡΙΓΡΑΦΗ ΥΠΗΡΕΣΙΑΣ: Data Cleansing – Part II

1. ΑΝΤΙΚΕΙΜΕΝΟ ΥΠΗΡΕΣΙΑΣ

Μετά την ολοκλήρωση του έργου του καθαρισμού και επιβεβαίωσης των δεδομένων πελατείας της ΔΕΗ, προέκυψε η ανάγκη για πρόσθετες τεχνικές εργασίες περαιτέρω εμπλουτισμού της master πληροφορίας πελατειακής βάσης.

Ειδικότερα, χρειάζεται να προστεθούν στοιχεία gender, στατιστικά στοιχεία ορθότητας της υφιστάμενης μεθοδολογίας ομαδοποίησης, προσθήκη κάποιων πεδίων σε αυτήν, περαιτέρω καθάρισμα σε στοιχεία emails, Αριθμών Δελτίων Ταυτότητας και Διαβατηρίων και εφαρμογή πρόσθετων business κανόνων.

Για τον λόγο αυτό η ΔΕΗ επιθυμεί να προσλάβει εξειδικευμένο Σύμβουλο για την υλοποίηση των τεχνικών αυτών εργασιών στην υφιστάμενη υποδομή της ΔΕΗ, δηλαδή MS Azure cloud με χρήση εργαλείων Information Server και Mnemosyne. Αναλυτικότερα, ο Σύμβουλος θα αναλάβει τον σχεδιασμό, την υλοποίηση και την συντήρηση των ροών εκτέλεσης των παραπάνω τεχνικών εργασιών καθώς και την υποστήριξη της αρμόδιας ομάδας της ΔΕΗ (Διεύθυνσης Στρατηγικής Δεδομένων & Ανάλυσης) στις περιόδους μετα-φόρτωσης δεδομένων στην νέα πλατφόρμα πελατοκεντρικής εξυπηρέτησης CRM.

2. ΣΤΟΙΧΕΙΑ ΠΑΡΕΧΟΜΕΝΗΣ ΥΠΗΡΕΣΙΑΣ

2.1 Γενικά

Στα πλαίσια του έργου, ο Ανάδοχος Σύμβουλος θα παραλάβει ένα dataset με την ακόλουθη master πληροφορία πελατειακής βάσης:

- Αριθμός Συμβολαίου (CA)
- Λεκτικά/Ονοματεπώνυμα Αντι-συμβαλλόμενων ή Company Names
- Πλήρη στοιχεία Διευθύνσεων B2B, Αποστολής Λογαριασμών και Μετρητών/Παροχών
- Τηλέφωνα επικοινωνίας
- Email επικοινωνίας
- Ημερομηνίες ένταξης & απένταξης συμβολαίων
- ΑΦΜ και ΔΟΥ
- Αριθμοί Δελτίων Ταυτότητας
- Αρ. Διαβατηρίου

καθώς και την υφιστάμενη ροή ομαδοποίησης σε επίπεδο πελάτη (φυσικού και νομικού προσώπου) που συμπληρώνει τα παραπάνω με το εξής πεδίο:

- Golden Record ID

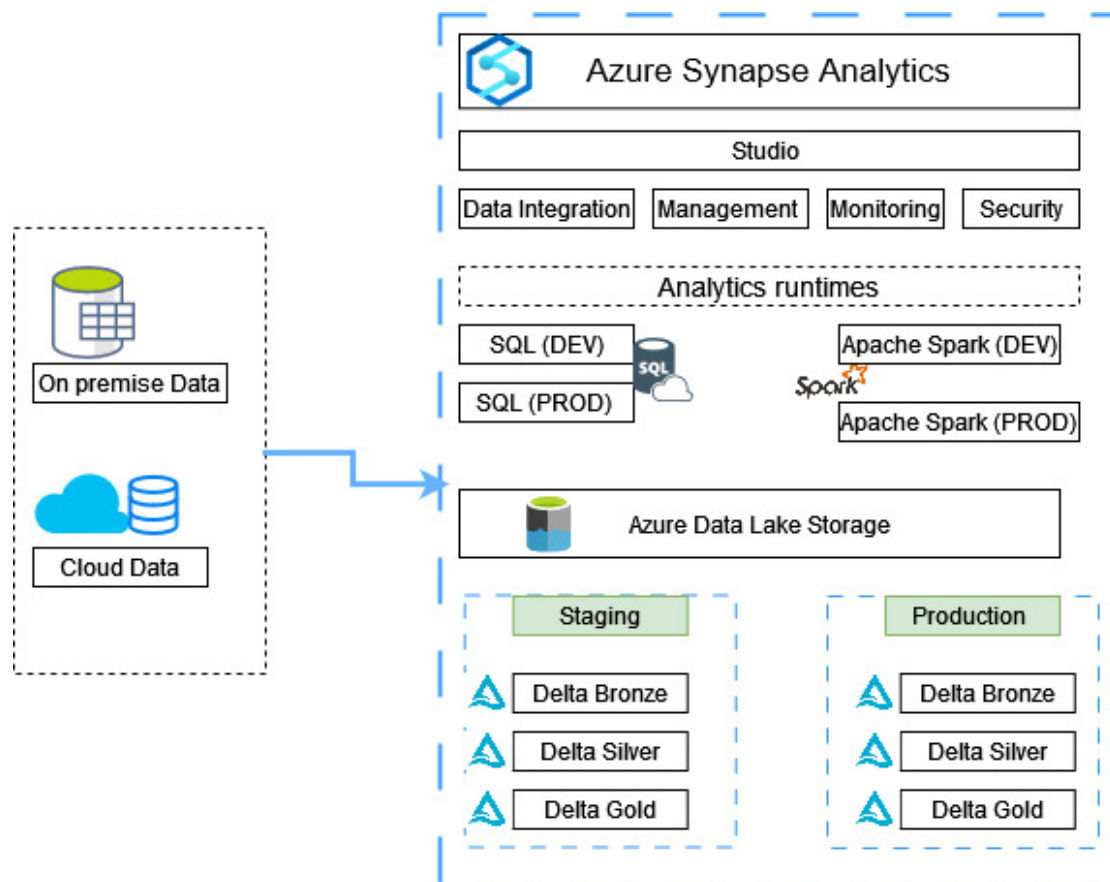
και τα αντίστοιχα Golden Record Group fields (δηλαδή Λεκτικά Ονοματεπώνυμα και Company Name, Διευθύνσεις αποστολής λογαριασμού και έδρας, τηλέφωνα επικοινωνίας και emails).

Στην υφιστάμενη ροή προβλέπεται η δυνατότητα τακτικής εβδομαδιαίας ανανέωσης στο κατάλληλα διαμορφωμένο production περιβάλλον του MS Azure cloud της ΔΕΗ.

Η αναμενόμενη υπηρεσία από τον εξωτερικό συνεργάτη θα περιλαμβάνει την τροποποίηση της υφιστάμενης ροής με τρόπο που να συμπεριλαμβάνει και τις ακόλουθες πρόσθετες προδιαγραφές, όπως αναφέρονται λεπτομερώς ακολούθως.

Ειδικότερα, η διαδικασία που θα ακολουθείται για την εκτέλεση στο παραγωγικό περιβάλλον κάθε αναγκαίας τροποποίησης είναι η εξής: Κάθε τροποποίηση θα υλοποιείται, και τεστάρεται στο κατάλληλα διαμορφωμένο staging περιβάλλον του MS Azure cloud της ΔΕΗ και μόνο μετά από ενδελεχείς UAT ελέγχους από την αρμόδια ομάδα της ΔΕΗ και το σχετικό green light θα περνούν οι εγκεκριμένες υλοποιημένες ροές στο κατάλληλα διαμορφωμένο production περιβάλλον του MS Azure cloud της ΔΕΗ.

Flow Chart



Ομάδα Υλοποίησης

Ο εξωτερικός συνεργάτης θα παρέχει ομάδα έμπειρων μηχανικών με σκοπό την υλοποίηση των παραπάνω διεργασιών στα πλαίσια του χρόνου που θα συμφωνηθεί και θα αποτυπωθεί λεπτομερώς στο χρονοδιάγραμμα (1^ο παραδοτέο του έργου στο τέλος της πρώτης εβδομάδας). Η ομάδα θα είναι πλήρως αφοσιωμένη στην εκτέλεση του έργου. Πιο συγκεκριμένα ο εξωτερικός συνεργάτης θα παρέχει:

- 2 senior Data Engineers
- 1 Data architect
- 1 Project / Delivery Manager

Όλη η ομάδα θα έχει πρόσβαση στο MS Azure cloud της ΔΕΗ. Όλα τα developments θα πραγματοποιούνται στο staging περιβάλλον και θα περνούν στο production μόνο μετά από έγκριση από την αρμόδια ομάδα της ΔΕΗ. “Way of working” θα συζητηθεί και θα συμφωνηθεί

μεταξύ των ομάδων κατά τη πραγματοποίηση των workshops που θα πραγματοποιηθούν κατά τη διάρκεια της 1^{ης} εβδομάδας.

2.2 Λεπτομερείς Προδιαγραφές

1. **Προσθήκη Φύλου Αντι-Συμβαλλόμενου (Gender):** Η προσθήκη του νέου πεδίου θα πρέπει να λάβει υπόψιν του: (i). τα λεξιλόγια γυναικείων και ανδρικών ονομάτων ελληνικής γλώσσας (με ελληνικούς και λατινικούς χαρακτήρες) καθώς και λεξιλόγια ξένων γυναικείων και ανδρικών ονομάτων (με λατινικούς χαρακτήρες), (ii). την κατάληξη του επωνύμου και (iii). τον βαθμό βεβαιότητας του αντίστοιχου υπολογισμού με στόχο η αρμόδια ομάδα της ΔΕΗ να μπορεί να αξιολογήσει την αξιοπιστία του αποτελέσματος και συνακόλουθα να είναι σε θέση να λάβει τεκμηριωμένη απόφαση για την τελική χρήση και μεταφόρτωση της πληροφορίας στην πλατφόρμα πελατοκεντρικής εξυπηρέτησης CRM.
2. **Αναγνώριση και διόρθωση email:** Στα email addresses που έχουν ήδη χαρακτηριστεί ως *invalid* θα εφαρμοσθεί περαιτέρω ανάλυση και επεξεργασία ώστε να: (i). προσδιορισθεί email μέσα σε κείμενο (π.χ. <dimitris arampatzis> dimisaram@gmail.com), (ii). συμπληρωθεί email (π.χ. apadopoulosstamatis@gmail) και (iii). διορθωθούν τυχόν τυπογραφικά σφάλματα (π.χ. thanasia.20@hotmail.con)
3. **Αναγνώριση και διόρθωση AT (στρατιωτικής, αστυνομικής, πολιτικής) & Διαβατήριο (Ελληνικό ή Ξένο):** Τα πεδία αριθμού ταυτότητας, αριθμού διαβατηρίου και χώρα προέλευσης («INSTITUTE») θα αξιοποιηθούν με κατάλληλο τρόπο ώστε να πραγματοποιηθούν όλες οι αναγκαίες εργασίες για να: (i) εντοπισθεί το κατάλληλο format, (ii). αναγνωρισθεί και (iii). αποθηκευτεί το ακριβές identifier. Ενδεικτικά παραδείγματα τέτοιου είδους εργασιών αποτελούν:
 - τυχόν αναγκαία μετατροπή χαρακτήρων από ελληνικούς σε λατινικούς και αντίστροφα,
 - εφαρμογή regular expressions με λεκτικά στρατιωτικών, αστυνομικών, πολιτικών ταυτοτήτων (όπως για παράδειγμα ΓΕΣ, ΓΕΝ, ΓΕΑ, ΓΕΕΘΑ, ΕΛΑΣ, κτλ.)
 - εφαρμογή κατάλληλων regular expressions για εντοπισμό διαβατηρίων, ανάλογα με την χώρα προέλευσηςΤο τελικό αποτέλεσμα αυτής της διαδικασίας θα είναι η τροποποίηση του υφιστάμενου πεδίου AT_Info με τις ακόλουθες διακριτές τιμές:
 - AT_Format
 - Invalid_Format
 - Passport_Format
 - Army_Police_Format
 - Nullκαθώς και ο σχετικός εμπλουτισμός του πεδίου CL_Passport με τα επιπλέον διαβατήρια που θα προκύψουν από τις παραπάνω πρόσθετες τεχνικές εργασίες.
4. **Αναγνώριση είδους πελάτη (customer type):** Στην υφιστάμενη υλοποίηση το είδος πελάτη έχει αναγνωρισθεί με βάση το αρχικό ψηφίο του VAT και συγκεκριμένα:
 - If starting_digit(VAT_ID) = 1 – 6 then Customer_Type προκύπτει από τα λεκτικά Ονοματεπωνύμου (λαμβάνοντας ως πιθανές τιμές person, organization/company, koinoxrista, municipality, other)

- If starting_digit(VAT_ID) = 7 – 9 then Customer_Type=organization
- If VAT_ID = null or invalid then Customer_Type = null

Στις περιπτώσεις που το VAT είναι αρχικά κενό αλλά στην συνέχεια έχει συμπληρωθεί μέσω του Golden Record Group οι παραπάνω κανόνες χρησιμοποιούνται για το ΑΦΜ που έχει βρεθεί μέσω Golden Record Group.

Στο σημείο αυτό αναμένονται από τον εξωτερικό συνεργάτη πρόσθετες προτάσεις κανόνων/best practices για περαιτέρω βελτίωση της ορθής αναγνώρισης τύπου πελάτη στο πελατολόγιο της ΔΕΗ και με βάση τις προηγούμενες σχετικές εμπειρίες.

5. **Αναγνώριση ορθότητας ευρέως χρησιμοποιούμενων ΑΦΜ με βάση τα λεκτικά (πχ. ΔΕΗ/ΕΥΔΑΠ, κτλ):** Στην πελατειακή βάση της ΔΕΗ ένα πολύ μεγάλο πλήθος CAs έχουν αντιστοιχισθεί εσφαλμένα στο ΑΦΜ της ΔΕΗ, ΕΥΔΑΠ, κ.τ.λ. πράγμα που θα πρέπει να αντικατασταθεί με null VAT και στην συνέχεια να ακολουθηθεί η ίδια διαδικασία χειρισμού των υπόλοιπων περιπτώσεων κενών ΑΦΜ. Πιο συγκεκριμένα θα πρέπει να εντοπισθεί το υποσύνολο των περιπτώσεων που στα λεκτικά εμφανίζονται σχετικοί όροι (πχ. ΔΕΗ, ΕΥΔΑΠ, κτλ) και μόνο σε αυτές να θεωρηθεί το ΑΦΜ έγκυρο. Στις υπόλοιπες θα πρέπει να γίνει η προ-αναφερόμενη αντικατάσταση με null ΑΦΜ.
6. **Αναγνώριση και απομόνωση εγγραφών CAs με συγκεκριμένα λεκτικά:** Λεκτικά όπως «Χωρίς Προμηθευτή», «Κομμένο» κ.τ.λ. στην πελατειακή βάση της ΔΕΗ δηλώνουν ανάγκη για εξαίρεση. Για τον λόγο αυτό η αρμόδια ομάδα της ΔΕΗ θα προσδώσει την σχετική λίστα εξαίρεσεων (υπό την μορφή keywords) στον εξωτερικό συνεργάτη ώστε να αναγνωρίσει, απομονώσει και εξαιρέσει από τις συνακόλουθες τεχνικές διαδικασίες τις αντίστοιχες εγγραφές.
7. **Αντικατάσταση κενών Billing Addresses με POD Addresses:** Στην πελατειακή βάση της ΔΕΗ υπάρχουν ~599.9K CAs με κενά Billing Addresses, εκ των οποίων τα ~599.8K έχουν συμπληρωμένα τα αντίστοιχα πεδία POD Addresses. Για τις τελευταίες περιπτώσεις θα πρέπει τα κενά Billing Addresses να αντικατασταθούν με τα PoD Addresses και να εφαρμοστούν όλες οι υπόλοιπες διαδικασίες Golden Record ομαδοποίησης στα εμπλουτισμένα δεδομένα διευθύνσεων.
8. **Κανονικοποίηση ονομάτων B2B_Company_Name:** Θα πρέπει να εφαρμοστεί κανονικοποίηση (κοινή γραφή) των B2B_Company_Name για τις κοινότητες/δήμους με γνωστά ονόματα.
9. **Ξεχωριστή υλοποίηση για Golden Record Groups τύπου ΠΟΛΛΑΠΛΩΝ:** Οι «ΠΟΛΛΑΠΛΟΙ» πελάτες στην ορολογία της ΔΕΗ αφορούν τιμολόγηση, μαζικές επικοινωνίες, sms/viber καμπάνιες, κτλ. και μπορεί να είναι «ενταγμένοι» στην υφιστάμενη πελατειακή βάση της ΔΕΗ ή όχι και γι' αυτό χρίζουν ειδικής μεταχείρισης. Ειδικότερα οι λεπτομέρειες της σχετικής αναγκαίας υλοποίησης ακολουθούν κατά περίπτωση:

A. Ιδιώτες

Ο «πελάτης» ορίζεται ως:

- i. CAs που έχουν ίδιο Αρ_Πολλαπλού

- ii. CAs με κενό Αρ_Πολλαπλού και ΑΦΜ ίδιο με το «Βασικό» ΑΦΜ του υπό εξέταση Αρ_Πολλαπλού, όπως εντοπίζεται στο πεδίο **VKTyp** του SAP ISU πίνακα **FKKVK**

B. Δημόσιο

Θα δημιουργηθεί μια ξεχωριστή κατηγορία Customer_Type_Dlmosio=Y, που όμως θα λαμβάνει τιμές “Y” μόνο για το σχετικό υποσύνολο των εγγραφών του customer_type και θα προέρχεται από το 2^ο ψηφίο του Εμπορικού Εταίρου = 4 και πιο συγκεκριμένα το πεδίο VBUND στον πίνακα FKKVKP.

Ο βασικός ορισμός «πελάτη» παραμένει ο ίδιος με παραπάνω, δηλαδή:

- i. CAs που έχουν ίδιο Αρ_Πολλαπλού
- ii. CAs με κενό Αρ_Πολλαπλού και ΑΦΜ ίδιο με το «Βασικό» ΑΦΜ του υπό εξέταση Αρ_Πολλαπλού, όπως εντοπίζεται στο πεδίο **VKTyp** του SAP ISU πίνακα **FKKVK**

Γ. Δήμοι – Περίπτωση I

Η κατηγορία «ΔΗΜΟΙ» εντοπίζεται από το Excel «Δήμοι Καλλικράτη» στην βάση του Αρ_Πολλαπλού (Στο προαναφερόμενο Excel αναφέρεται ως “ΛΟΓ. ΣΥΜΒ. SAP”. Πιο συγκεκριμένα ο «πελάτης» είναι η κάθε κοινότητα του κάθε Δήμου (δηλαδή η ξεχωριστή εγγραφή του συνημμένου Excel με τους Καλλικρατικούς Δήμους:

- i. Όλες οι κοινότητες / διαφορετικοί Αρ_Πολλαπλού όπως εμφανίζονται στο συνημμένο Excel και τα διακριτά CAs που ανήκουν στον κάθε ένα από αυτούς τους πολλαπλούς
- ii. CAs με κενό Αρ_Πολλαπλού και ΑΦΜ ίδιο με του κάθε Δήμου στον οποίο αντιστοιχεί ο κάθε Αρ_Πολλαπλού

Πιο συγκεκριμένα η διασύνδεση πρέπει να γίνει πάνω στον Αρ.Πολλαπλού (ονομασία «ΛΟΓ.ΣΥΜΒ SAP”- στήλη B Excel Καλλικράτη) και θα πρέπει να συμπεριλαμβάνονται στον τελικό πίνακα οι στήλες C – Κοινότητα, D – κωδικός Καλλικράτη και K – Δήμος Καλλικράτη από το Excel «Δήμοι Καλλικράτη». Στο σημείο αυτό αποσαφηνίζεται ότι η πληροφορία της στήλης K – Δήμος Καλλικράτη ουσιαστικά θα υλοποιείται μέσω της κατηγορίας «[Πολλαπλοί Πολλαπλοί](#)» που ακολουθεί.

Δεδομένου ότι όλη η διαδικασία γίνεται στο Azure, το Excel βρίσκεται αποθηκευμένο σε κάποιον πίνακα, θα γίνεται import (από κάποιο συγκεκριμένο repo) ? Το αρχείο υποθέτουμε ότι θα είναι fix και δεν θα χρειάζεται ανανέωση.

Γ. Δήμοι – Περίπτωση II

Όσα δεν έχουν Αρ_Πολλαπλού ούτε ΑΦΜ που ανήκει σε Πολλαπλό θα αναγνωριστούν με fuzzy matching όλα τα λεκτικά που περιλαμβάνουν κοινότητες κι έτσι να ενταχθούν σε διαφορετικά Golden Record Groups και customer_type=ΔΗΜΟΙ. Για τις περιπτώσεις όπου στο όνομα υπάρχει επιπλέον πληροφορία εκτός από το όνομα Δήμου/Κοινότητα, (πχ. ΔΗΜΟΣ ΠΕΡΙΣΤΕΡΙΟΥ ΑΝΟΙΚΤ.ΚΟΛΥΜΒΗΤΗΡ., ΔΗΜΟΣ ΧΑΛΚΙΔΑΣ PARKING ΔΗΜ. ΑΓΟΡΑΣ, ΒΡΕΦΟΝΗΠΙΑΚΟΣ ΣΤΑΘΜΟΣ ΔΗΜΟΥ ΑΛΙΜΟΥΚΟΙΝΟΤΙΚΟ ΑΝΤΛΙΟΣΤ ΝΑΟΥΣΑΣ ΠΑΡΟΥ, ΔΗΜΟΤΙΚΟ ΑΝΤΛΙΟΣΤΑΣΙΟ...) το company_type θα χαρακτηριστεί ως ΔΗΜΟΙ/municipality.

Σημειώνεται ότι στις περιπτώσεις αυτές δεν θα υπάρχει αντίστοιχος Κωδικός Καλλικρατικού Δήμου, καθώς η περίπτωση αυτή δεν εντάσσεται ούτε στους «Ενταγμένους» ούτε στους «Ανένταχτους».

Τέλος οι περιπτώσεις που δεν αναφέρουν τον όνομα Δήμου αλλά 'παραπέμπουν' σε ΔΗΜΟ (πχ. ΔΗΜΟΤΙΚΟ ΑΝΤΛΙΟΣΤΑΣΙΟ, ΚΟΙΝ.ΚΑΜΠΙΓΚ, ΚΟΙΝΟΤΙΚΗ ΑΠΟΧΕΤΕΥΣΗ, ΦΟΠ ΠΛΑΤΕΙΑΣ ΚΕΡΑΣΙΑ, ΔΗΜΟΤΙΚΟ ΣΧΟΛ. 7, 1 ΔΗΜΟΤΙΚΟ ΣΧΟΛΕΙΟ ...) δεν θα συμπεριλαμβάνονται στην κατηγορία customer_type=ΔΗΜΟΙ/municipalit.

Δ. Πολλαπλοί «Πολλαπλοί»

Για τις περιπτώσεις που περισσότεροι από 1 αριθμοί πολλαπλών αντιστοιχούν στον ίδιο «πελάτη» θα δημιουργηθεί ξεχωριστό πεδίο που να ομαδοποιεί τους πολλαπλούς Αριθμούς_Πολλαπλών με το όνομα Multiple_Pollaplos. Το σχετικό groupάρισμα θα γίνει με όμοια διαδικασία fuzzy matching στα λεκτικά των επωνυμιών, όπως γίνεται στις υπόλοιπες περιπτώσεις Golden Record group.

10. Αναγνώριση περιπτώσεων Πολλαπλών με «λάθος καταχωρημένο ΑΦΜ»: Για τις περιπτώσεις «Μη ενταγμένων» Πολλαπλών με χρήση Βασικού ΑΦΜ Πολλαπλού θα πρέπει να γίνει εξαντλητικός (exhaustive) έλεγχος ορθής αντιστοίχισης Βασικού ΑΦΜ και λεκτικών ονοματεπωνύμων αντίστοιχων εγγραφών Contract Account. Για τις περιπτώσεις που εντοπίζονται αποκλίσεις τα βασικά ΑΦΜ θα πρέπει να διορθωθούν/ακυρωθούν κατάλληλα σε συμφωνία με την αρμόδια ομάδα της ΔΕΗ.

11. Δημιουργία πεδίου «Μέθοδος Ομαδοποίησης» ειδικά για την περίπτωση Πολλαπλών ώστε να διαφοροποιείται η μέθοδος ομαδοποίησης των CAs σε κάθε Golden Record Group: Το πεδίο «Μέθοδος Ομαδοποίησης» μπορεί να παίρνει τις τιμές: «Ενταγμένος», «Ανένταχτος» και «Αλγόριθμος». Η τιμή «Ενταγμένος» προέρχεται από ΑΦΜ ή Αρ_Πολλαπλού, η τιμή «Ανένταχτος» από τους ανένταχτους πολλαπλούς όπως περιγράφονται παραπάνω (δηλαδή «βασικό» ΑΦΜ Πολλαπλού) και η τιμή «Αλγόριθμος» από τα matching criteria & fuzzy matching τεχνικές, όπως περιεγράφηκαν παραπάνω.

12. Ένταξη στην διαδικασία matching για Golden Record Group Analysis πεδίων σχετικών με Ebill: Η αναγνώριση Golden Record Groups θα πρέπει να συνυπολογίζει και τα πεδία Ebill_User_Name και Ebill_Email (που δεν χρησιμοποιούνται στην υφιστάμενη διαδικασία).

13. Ένταξη πεδίων σχετικών με Ταυτότητες, Διαβατήρια & E-bill στα Golden Record Group – level πεδία: Ανάμεσα στα υπόλοιπα πεδία επιπέδου Golden Record Group που ήδη περιλαμβάνονται στο υφιστάμενο τελικό output dataset που θα παραλάβει ο εξωτερικός ανάδοχος (δηλ. Λεκτικά Ονοματεπώνυμα και Company Name, Διευθύνσεις αποστολής λογαριασμού και έδρας, τηλέφωνα επικοινωνίας και emails) θα πρέπει να προστεθούν:

- πεδία ταυτοτήτων AT, διαβατηρίων Passport όπως περιεγράφηκαν παραπάνω και συγκεκριμένα και τα πεδία ισχύος των εν λόγω εγγράφων (δηλ. ID_VALID_DATE_FROM, ID_AT_INSTITUTE, Passport_VALID_DATE_TO)
- πεδία που σχετίζονται με το Ebill account (δηλ. GR_Ebill_Activation_Date, GR_Ebill_User_Name, GR_Password, GR_Ebill_Delete_Date, GR_Ebill_Transformed_Email).

14. Δημιουργία κοινής μεθοδολογίας συμπλήρωσης πεδίων επιπέδου Golden Record Group από τα υφιστάμενα πεδία επιπέδου CA: Τα διαφορετικά πεδία επιπέδου Golden Record Group θα πρέπει να προέρχονται από την πιο συχνή τιμή κάθε αντίστοιχου πεδίου από τα διαφορετικά CAs που ανήκουν στο ίδιο Golden Record Group. Μοναδική εξαίρεση αποτελούν τα πεδία που σχετίζονται με Ταυτότητες και Διαβατήρια και το Ebill για τα οποία θα χρησιμοποιούνται η πιο πρόσφατη ημερομηνία έκδοσης (αντίστοιχα πεδία: ID_ VALID_DATE_FROM και Ebill_Activation_Date).

15. Δημιουργία GR_Customer_Type που θα αφορά το είδος πελάτη του Golden Record Group και όχι του CA (σε επίπεδο Golden Record Group)

16. Υλοποίηση Extra post-processing requirements: Θα χρειαστεί να υλοποιηθούν κάποιοι πρόσθετοι κανόνες ομαδοποίησης CAs ή/και τροποποίησης της αλγοριθμικής/αυτόματης διαδικασίας ένταξης σε Golden Record groups με βάση business κανόνες που θα προδιαγραφούν από την αρμόδια ομάδα της ΔΕΗ ή/και τον οπτικό έλεγχο των αποτελεσμάτων που θα προκύψουν κατά την διάρκεια του έργου

17. Υποστήριξη για τις ανάγκες μεταφόρτωσης των δεδομένων στην νέα CRM πλατφόρμα: Στα πλαίσια της υποστήριξης της διαδικασίας προετοιμασίας και μεταφόρτωσης των δεδομένων στην νέα CRM πλατφόρμα του οργανισμού (Salesforce), ο εξωτερικός ανάδοχος θα χρειαστεί να υποστηρίξει την αρμόδια ομάδα της ΔΕΗ για σταδιακές φορτώσεις και επανα-φορτώσεις δεδομένων, παράδοση reconciliation reports και φυσικά υποστήριξη και συμμετοχή κατά το χρονικό διάστημα μετάβασης στο SF.

18. Παροχή score ομοιότητας εγγραφών CAs που έχουν ομαδοποιηθεί στο ίδιο Golden Record Group σε κοινή κλίμακα αξιολόγησης: Στόχος του εν λόγω score, που εφεξής καλούμε **Composite Similarity Score**, είναι η αποτίμηση του ποσοστού βεβαιότητας της κατάταξης ή μη ένταξης κάθε εγγραφής σε ένα Golden Record group προκειμένου για την τεκμηριωμένη αξιολόγηση από την αρμόδια ομάδα της ΔΕΗ. Στο απαιτούμενο score ομοιότητας θα πρέπει να συνυπολογιστούν κατ'ελάχιστον:

- το είδος της κατάταξης της κάθε εγγραφής (δηλ. Main Record, Duplicate, Clerical, Residual),
- το πλήθος των απαιτούμενων passes για την τελική κατάταξη ή/και μη ένταξη,
- ο τύπος του (-ων) πεδίου(-ων) που χρησιμοποιείται για blocking ή/και matching criteria (πχ λεκτικά Ονοματεπώνυμο, VAT, ΑΔΤ, Αρ. Διαβατηρίου, Διευθύνσεις, τηλέφωνα επικοινωνίας, email, customer type, κτλ.),
- το αν το κάθε ένα από αυτά τα πεδία είναι κενό ή περιέχει αξιοποιήσιμη πληροφορία

Για το εν λόγω score ομοιότητας η ομάδα της ΔΕΗ αναμένει από τον εξωτερικό συνεργάτη να προτείνει την ακριβή μεθοδολογία που ανταποκρίνεται με τον καλύτερο δυνατό τρόπο στα δεδομένα της ΔΕΗ. Ενδεικτικά παραδείγματα αποτελούν η χρήση των σταθμίσεων ομοιότητας που παρέχονται από την πλατφόρμα, distance functions όπως η Levensthein distance ή/και η ομοιότητα συνημιτόνου (cosine similarity), παραλλαγές αυτών ή/και κατάλληλοι συνδυασμοί μεταξύ τους.

19. Βελτίωση Ομαδοποίησης CAs και με βάση τεχνικές διαδικασίες fuzzy matching λεκτικών πεδίων CAs: Θα πρέπει να υλοποιηθούν στατιστικές και λεξικογραφικές

μέθοδοι ομοιότητας σε κάθε πιθανό ζεύγος «όμοιων» εγγραφών. Για τον σκοπό αυτό προϋποτίθεται η εκτέλεση όλων των τυχόν αναγκαίων κανονικοποιήσεων σε όρους που συναντιούνται συχνά στα δεδομένα της ΔΕΗ, όπως για παράδειγμα λεκτικά που αφορούν Κοινόχρηστα, Δήμους, Δημοτικά Σχολεία, Αντλιοστάσια, Στρατόπεδα, κτλ). Στην υλοποίηση της ομαδοποίησης με χρήση τεχνικών fuzzy matching λεκτικών θα πρέπει να συμπεριληφθεί και το αντίστοιχο confidence level (επίπεδο σιγουριάς) ομοιότητας κάθε πιθανού ζεύγους, που με την σειρά του θα συνεκτιμά ανάμεσα σε άλλους πιθανούς παράγοντες και το πλήθος αναγνωριστικών πεδίων που χρησιμοποιήθηκαν για τον σκοπό αυτό καθώς και οι κατάλληλες σταθμίσεις. Ο εξωτερικός συνεργάτης αναμένεται να περιγράψει και υλοποιήσει την ακριβή προτεινόμενη για τον σκοπό αυτό μεθοδολογία. Τα αποτελέσματα θα συγκριθούν με τα υφιστάμενα, ώστε να διασφαλιστεί από την αρμόδια ομάδα της ΔΕΗ η σχετική βελτίωση που θα επέλθει από το σχετικό παραδοτέο.

20. Δημιουργία αυτόματου μηχανισμού delta επικαιροποίησης: Η διαδικασία αυτή θα πρέπει να περιλαμβάνει τις αλλαγές που έχουν πραγματοποιηθεί στα δεδομένα ανάμεσα στα δυο διαδοχικά runs, δηλαδή: (i). πιθανές τροποποιήσεις σε CAs που υπήρχαν στο προηγούμενο run και είχαν κατηγοριοποιηθεί ως Master, Duplicates, Clerical ή Residuals και είχαν αντίστοιχα συμπεριληφθεί ή όχι σε κάποιο Golden Record Group και (ii). νέα συμβόλαια CAs. Στο σημείο αυτό αποσαφηνίζεται ότι οι πιθανές τροποποιήσεις σε υφιστάμενα συμβόλαια όπως περιγράφονται στο (i) παραπάνω ενδέχεται να προκαλέσουν διαφορετικό χαρακτηρισμό των εν λόγω CAs κι επομένως απένταξη ή διαφορετική ένταξη σε Golden Record Groups. Τα νέα συμβόλαια όπως αναφέρονται στο (ii) παραπάνω θα πρέπει να συγκριθούν με την προτεινόμενη μεθοδολογία “Composite Similarity Score” με όλα τα Golden Record Groups προκειμένου να εντοπισθεί η ορθότερη ένταξη τους. Σε κάθε κύκλο τακτικής (εβδομαδιαίας) ανανέωσης ο πλήρης μηχανισμός καθαρισμού δεδομένων και Golden Record Analysis θα πρέπει να εφαρμόζεται μόνο σε όσα από τα records/CAs πληρούν τις παραπάνω προδιαγραφές, που θα πρέπει να αναγνωρίζονται με έναν γρήγορο και εύκολο τρόπο μέσω κατάλληλου flagγαρίσματος.

21. Διατήρηση σταθερού Golden Record ID μεταξύ διαφορετικών runs του μηχανισμού τακτικής (εβδομαδιαίας) ανανέωσης: Ανάμεσα στα διαδοχικά runs τα Golden Record Group identifiers πρέπει να παραμένουν σταθερά προκειμένου να μπορεί να δουλέψει ο αυτόματος μηχανισμός delta επικαιροποίησης, όπως περιγράφεται παραπάνω. Αυτό σημαίνει ότι το identification των Golden Record Groups απαιτείται να είναι ανεξάρτητο από τα ακριβή CA-μέλη του, καθώς πιθανές τροποποιήσεις των στοιχείων κάποιου/-ων από αυτά ενδέχεται να τα αλλάξουν ανάμεσα σε διαδοχικά runs και μόνο με την διατήρηση της σταθερότητας για τα εναπομείναντα μέλη θα μπορεί να επιτευχθεί η ορθότητα των υπολογισμών σύμφωνα με την προτεινόμενη μέθοδο “Composite Similarity Score” για την ορθή ένταξη των νέων CAs σε κάποιο από τα ήδη υπάρχοντα Golden Record groups (που έχουν δημιουργηθεί είτε στο προηγούμενο run, ακόμα κι αν τα ακριβή μέλη τους μπορεί να έχουν μεταβληθεί στο νέο run, είτε στο νέο run).

22. Δημιουργία log files : Θα πρέπει να δημιουργούνται logs αρχεία μέσω των οποίων θα γίνεται ο έλεγχος των διεργασιών της πλατφόρμας. Πιο συγκεκριμένα, χρειάζεται να καταγράφονται σε κάποιο αρχείο οι χρήστες που συνδέονται στο περιβάλλον εργασίας καθώς και οι εργασίες οι οποίες εκτελούνται σε αυτό.

3. ΠΡΟΤΑΣΗ ΥΛΟΠΟΙΗΣΗΣ / TASKS

Εργασία	Υπό εργασία	Περιγραφή Εργασίας	Μεθοδολογία
1	1.1	Προσθήκη Φύλου Αντί-Συμβαλλόμενου (Gender)	Αντιστοίχιση του ονόματος με βάση δεδομένων που περιέχει όνομα και φύλλο και δυνατότητα διόρθωσης του ονόματος σε περίπτωση λανθασμένης καταχώρησης με την εύρεση του πιο συναφούς ονόματος από τη βάση. Ενδεικτικά : Αξιοποίηση ανοιχτών βάσεων δεδομένων (UCI: University of California Irvine)
2	2.1	Αναγνώριση και διόρθωση email	Αναγνώριση διεύθυνσης email πελάτη, εντοπισμός παρόχου email και διόρθωση τυπογραφικών με χρήση regular expressions
3	3.1	Αναγνώριση και διόρθωση AT (στρατιωτικής, αστυνομικής, πολιτικής) & Διαβατήριο (Ελληνικό ή Ξένο)	Regular expressions, έλεγχος format, έλεγχος αριθμού ψηφίων / λεκτικών (length validation)
4	4.1	Αναγνώριση είδους πελάτη (customer type):	Εφαρμογή κανόνων με βάση το VAT. Εναλλακτικές προτάσεις θα προκύψουν μετά την ολοκλήρωση των workshops.
5	5.1	Αναγνώριση ορθότητας ευρέως χρησιμοποιούμενων ΑΦΜ με βάση τα λεκτικά	Δημιουργία dimension πίνακα στον οποίο θα διατηρούνται τα ευρέως χρησιμοποιούμενα ΑΦΜ. Έλεγχος κάθε ΑΦΜ με τον πίνακα (join , case when expressions) και επαλήθευση ή ακύρωση (αντικατάσταση με «null») του πεδίου
6	6.1	Αναγνώριση και απομόνωση εγγραφών CAs με συγκεκριμένα λεκτικά	Αντιστοίχιση με δεδομένη λίστα εξαιρέσεων
7	7.1	Αντικατάσταση κενών Billing Addresses με POD Addresses	Εφαρμογή διαδικασιών Golden Records στα PoD addresses και συμπλήρωση των billing με βάση των PoD

8	8.1	Κανονικοποίηση ονομάτων B2B_Company_Name	Επιλογή «κανονικών» ονομάτων και καταχώρηση σε λίστα. Αντιστοίχιση με το πιο συναφές company name με χρήση regular expressions
9	9.1	Golden Record Groups τύπου ΠΟΛΛΑΠΛΩΝ για Ιδιώτες	Ορισμός ως «πολλαπλό» αν έχει αριθμό πολλαπλού και μετέπειτα ομαδοποίηση ή έλεγχος για πολλαπλούς λογαριασμούς με ίδιο ΑΦΜ στην περίπτωση κενού αριθμού πολλαπλού και ομαδοποίηση κατά κύριο ΑΦΜ.
	9.2	Golden Record Groups τύπου ΠΟΛΛΑΠΛΩΝ για Δημόσιο	Παρόμοια διαδικασία με 9.1 συν αντιστοιχία με τη σημαία ένδειξης δημόσιο ή όχι από το δεδομένο πίνακα
	9.3.1	Golden Record Groups τύπου ΠΟΛΛΑΠΛΩΝ για Δήμους – Καλλικράτης	Συσχέτιση με βάση το excel που περιέχει τους δήμους Καλλικράτη
	9.3.2	Golden Record Groups τύπου ΠΟΛΛΑΠΛΩΝ για Δήμους – ΟΧΙ Καλλικράτης	Αντίστοιχο με 9.3.1 για εγγραφές που παραπέμπουν δε Δήμο αλλά δεν είναι στο αρχείο Καλλικράτη
	9.4	Golden Record Groups τύπου Πολλαπλοί «Πολλαπλοί»	Εφαρμογή regular expressions ή/και fuzzy matching τεχνικών στα λεκτικά των επωνυμιών για ομαδοποίηση πολλαπλών που αντιστοιχούν στον ίδιο πελάτη. Για την υλοποίηση fuzzy matching (ενδεικτικά): <ul style="list-style-type: none"> • Levenshtein Distance • Similarity Score • Στατιστικά έγκυρων πεδίων (πόσα πεδία αξιοποιούνται για την κατηγοριοποίηση)
10	10.1	Αναγνώριση περιπτώσεων Πολλαπλών με «λάθος καταχωρημένο ΑΦΜ»	Αντιστοίχιση βάση ονόματος και κατά συνέπεια ΑΦΜ ή αναζήτηση ΑΦΜ με απόκλιση μερικών (ενός-δύο) χαρακτήρων για την περίπτωση του ορθογραφικού.
11	11.1	Δημιουργία πεδίου «Μέθοδος Ομαδοποίησης» ειδικά για την περίπτωση Πολλαπλών ώστε να διαφοροποιείται η μέθοδος ομαδοποίησης των CAs σε κάθε Golden Record Group	Δημιουργία τριών ξεχωριστών ομάδων όπως εκείνες περιγράφονται : <ul style="list-style-type: none"> • «Ενταγμένος» με βάση ΑΦΜ ή Αρ_Πολλαπλού • «Ανένταχτος» με βάση «βασικό» ΑΦΜ Πολλαπλού • «Αλγόριθμος» με fuzzy matching τεχνικές
12	12.1	Ένταξη στην διαδικασία matching για Golden Record Group Analysis πεδίων σχετικών με Ebill	Εφαρμογή κανόνων Golden Record για τα πεδία e-bill username και email
13	13.1	Ένταξη πεδίων σχετικών με Ταυτότητες, Διαβατήρια & E-bill στα	Εφαρμογή κανόνων Golden Record για τα πεδία ταυτότητας, διαβατηρίου και e-bill username και email

		Golden Record Group – level πεδία	
14	14.1	Δημιουργία κοινής μεθοδολογίας συμπλήρωσης πεδίων επιπέδου Golden Record Group από τα υφιστάμενα πεδία επιπέδου CA	Σε περίπτωση διπλών εγγραφών, διατήρηση της πιο πρόσφατης με βάση την ημερομηνία έκδοσης λογαριασμού
15	15.1	Δημιουργία GR_Customer_Type που θα αφορά το είδος πελάτη του Golden Record Group και όχι του CA	Ομαδοποίηση πελατών βάση συγκεκριμένων πεδίων εκτός CA.
16	16.1	Υλοποίηση Extra post-processing requirements	Εφαρμογή business κανόνων που θα δοθούν στην ομάδα υλοποίησης (python / sql /spark)
17	17.1	Υποστήριξη για τις ανάγκες μεταφόρτωσης των δεδομένων στην νέα CRM πλατφόρμα	Ad-hoc support
18	18.1	Παροχή score ομοιότητας εγγραφών CAs που έχουν ομαδοποιηθεί στο ίδιο Golden Record Group σε κοινή κλίμακα αξιολόγησης	Ανάπτυξη και υλοποίηση μεθοδολογίας ασαφής αντιστοίχισης κειμένου με σκοπό την τεχνική εύρεση συμβολοσειρών που ταιριάζουν με ένα μοτίβο κατά προσέγγιση και όχι ακριβώς (fuzzy matching) Ενδεικτικά: <ul style="list-style-type: none"> • Levenshtein Distance • Similarity Score • Στατιστικά έγκυρων πεδίων (πόσα πεδία αξιοποιούνται για την κατηγοριοποίηση)
19	19.1	Βελτίωση Ομαδοποίησης CAs και με βάση τεχνικές διαδικασίες fuzzy matching λεκτικών πεδίων CAs	Παρόμοια με 18.1 (fuzzy matching) , scoring και εφαρμογή ορίων (κατώφλι απόφασης). Επιπλέον εφαρμογή regular expressions , όπου είναι εφικτό χρησιμοποιώντας λέξεις κλειδιά .
20	20.1	Δημιουργία αυτόματου μηχανισμού delta επικαιροποίησης	Δημιουργία Delta Lake σε Azure : <ul style="list-style-type: none"> • Διατήρηση ιστορικών εκδοχών των διαδοχικών runs • Άμεσα προσβάσιμα δεδομένα • Σύγκριση και δυνατότητα ανάλυσης αλλαγών και κατά συνέπεια δημιουργία versioning των Golden Record Groups
21	21.1	Διατήρηση σταθερού Golden Record ID μεταξύ διαφορετικών runs του μηχανισμού τακτικής (εβδομαδιαίας) ανανέωσης	Διατήρηση μέσω διαφορετικών εκδοχών (delta lake) και/ ή δημιουργία dimension πίνακα στον οποίο θα διατηρούνται τα Golden Record IDs από κάθε run και με συνδυασμό (join) θα εξασφαλίζουμε τη διατήρηση του κλειδιού.

22	22.1	Logging εφαρμογής	<p>Δημιουργία logs από το περιβάλλον Azure. Ενδεικτικά :</p> <ul style="list-style-type: none"> • Active directory logs • Storage logs • Activity logs <p>Παραμετροποίηση συχνότητας εγγραφής , διατήρηση ιστορικού και χώρου αποθήκευσης με βάση τη διαθεσιμότητα του περιβάλλοντος εργασίας.</p>
22	22.2	Logging διεργασιών	<p>Προτείνουμε σαν extension του «κλασικού» logging της εφαρμογής, την καταγραφή και ανάλυση των διεργασιών cleansing (υπολογισμοί , διορθώσεις, κατηγοριοποιήσεις) μέσω περιγραφικών στατιστικών. (π.χ. ποσοστό διόρθωσης ΑΦΜ, ποσοστό πελατών που ανήκουν σε κάποια συγκεκριμένη κατηγορία) .</p>

4. ΠΑΡΑΔΟΤΕΑ – ΔΙΑΡΚΕΙΑ ΕΡΓΟΥ

Ο εξωτερικός σύμβουλος υποχρεούται να παραδώσει τα ακόλουθα:

- 1) Λεπτομερές χρονο-διάγραμμα του έργου
- 2) Τελικό consolidated output dataset με τις πρόσθετες προδιαγραφές που περιγράφονται παραπάνω στο αποτέλεσμα των πιο πρόσφατων επικαιροποιημένων στοιχείων βάσης δεδομένων της ΔΕΗ
- 3) Ροές που υλοποιούν τις παραπάνω προδιαγραφές φορτωμένες και στο staging και production περιβάλλον στο MS Azure της ΔΕΗ σύμφωνα με τις παραπάνω διαδικασίες
- 4) Κάθε τροποποίηση που υλοποιείται πρέπει να περνά στο staging περιβάλλον προς UAT έλεγχο από την αρμόδια ομάδα της ΔΕΗ και μόνο μετά από το green light να περνά στο production περιβάλλον
- 5) Τεκμηρίωση και περιγραφή της μεθοδολογίας και του κώδικα/ροών που θα παραδοθούν, καθώς και training της αρμόδιας ομάδας της ΔΕΗ

Η ΔΕΗ επιθυμεί το πλάνο ολοκλήρωσης του έργου να μην υπερβαίνει συνολικά τις δέκα (10) εργάσιμες εβδομάδες. Ειδικότερα η ΔΕΗ επιθυμεί από την ημερομηνία πρόσδοσης προσβάσεων, παράδοσης της βάσης δεδομένων **και παράδοσης των business κανόνων όπου εκείνοι απαιτούνται** ο ανάδοχος σύμβουλος να έχει διεκπεραιώσει όλα τα παραδοτέα το αργότερο εντός εννέα (9) εργασίμων εβδομάδων. Επίσης, κατά την διάρκεια της πρώτης (1^{ης}) εργάσιμης εβδομάδας ο ανάδοχος υποχρεούνται να παραδώσει το λεπτομερές χρονοδιάγραμμα εργασιών του έργου, που αποτελεί το παραδοτέο νούμερο 1 του έργου **καθώς και να έχουν ολοκληρωθεί τα workshops με την ομάδα της ΔΕΗ με σκοπό την αποσαφήνιση τυχών περαιτέρω επεξηγήσεων στα δεδομένα και στους business κανόνες που θα παραδοθούν στον ανάδοχο** .

Επιπλέον, αποτελεί υποχρέωση του συμβούλου να παρέχει υποστήριξη και μετά την ολοκλήρωση του έργου και για χρονικό διάστημα τουλάχιστον ενός (1) μήνα μετά στην αρμόδια ομάδα της ΔΕΗ αναφορικά με επεξηγήσεις και διευκρινίσεις που πιθανόν να

απαιτηθούν για τα παραδοτέα, καθώς και στις συγκεκριμένες ανάγκες σταδιακών φορτώσεων δεδομένων στην νέα πλατφόρμα SF και στο τελικό χρονικό διάστημα μεταφόρτωσης δεδομένων πριν από το εμπορικό λανσάρισμα της νέας πλατφόρμας SF.

5. ΧΡΟΝΟΔΙΑΓΡΑΜΜΑ

	Weeks									
	M0				M1				M2	
	W0	W1	W2	W3	W4	W5	W6	W7	W8	W9
Εργασία 0: Παράδοση business κανόνων και πραγματοποίηση workshops										
Εργασία 0 :Λεπτομερές χρονο-διάγραμμα του έργου										
Εργασία 0 : Σχεδιασμός Διαδικασίας Ανάλυσης Δεδομένων										
Εργασία 1: Προσθήκη Φύλου Αντί-Συμβαλλόμενου (Gender)										
Εργασία 2: Αναγνώριση και διόρθωση email										
Εργασία 3: Αναγνώριση και διόρθωση AT (στρατιωτικής, αστυνομικής, πολιτικής) & Διαβατήριο (Ελληνικό ή Ξένο)										
Εργασία 4: Αναγνώριση είδους πελάτη (customer type):										
Εργασία 5: Αναγνώριση ορθότητας ευρέως χρησιμοποιούμενων ΑΦΜ με βάση τα λεκτικά										
Εργασία 6: Αναγνώριση και απομόνωση εγγραφών CAs με συγκεκριμένα λεκτικά										
Εργασία 7: Αντικατάσταση κενών Billing Addresses με POD Addresses										
Εργασία 8: Κανονικοποίηση ονομάτων B2B_Company_Name										
Εργασία 9: Golden Record Groups τύπου ΠΟΛΛΑΠΛΩΝ										
Εργασία 10: Αναγνώριση περιπτώσεων Πολλαπλών με «λάθος καταχωρημένο ΑΦΜ»										
Εργασία 11: Δημιουργία πεδίου «Μέθοδος Ομαδοποίησης» ειδικά για την περίπτωση Πολλαπλών ώστε να διαφοροποιείται η μέθοδος ομαδοποίησης των CAs σε κάθε Golden Record Group										
Εργασία 12: Ένταξη στην διαδικασία matching για Golden Record Group Analysis πεδίων σχετικών με Ebill										
Εργασία 13: Ένταξη πεδίων σχετικών με Ταυτότητες, Διαβατήρια & E-bill στα Golden Record Group – level πεδία										
Εργασία 14: Δημιουργία κοινής μεθοδολογίας συμπλήρωσης πεδίων επιπέδου Golden Record Group από τα υφιστάμενα πεδία επιπέδου CA										
Εργασία 15: Δημιουργία GR_Customer_Type που θα αφορά το είδος πελάτη του Golden Record Group και όχι του CA										
Εργασία 16: Υλοποίηση Extra post-processing requirements										
Εργασία 17: Υποστήριξη για τις ανάγκες μεταφόρτωσης των δεδομένων στην νέα CRM πλατφόρμα	AD HOC REQUEST									

[illegible]